

Turn Detector

Детектор конца реплики для голосовых AI-агентов

Талгат Букенов

AI Engineer — Machine Learning | Март 2026



Проблема

Голосовые боты часто не знают, когда пользователь закончил говорить. В результате:

- Задержки — бот ждёт слишком долго и UX кажется медленным.
- Прерывания — бот начинает отвечать, пока пользователь ещё говорит.

Решение: ML-модель, предсказывающая «end-of-turn» на основе текстовой транскрипции.


Данные

Данные: MultiWOZ 2.2

- 8,437 диалогов (бронирование отелей, ресторанов, такси)
- Открытый датасет с HuggingFace
- Только реплики пользователя (USER), не системы

Prefix Sampling

- Каждая реплика $\rightarrow$ N префиксов (N = число слов)
- "I want a hotel" $\rightarrow$ 4 примера:
 - "I" $\rightarrow$ 0, "I want" $\rightarrow$ 0, "I want a" $\rightarrow$ 0, "I want a hotel" $\rightarrow$ 1
- Итого: **153,983 примера** из 2000 диалогов



```
attachEvent("onreadystatechange",H),e.attachE
boolean Number String Function Array Date RegE
_={};function F(e){var t=_[e]={};return b.ea
t[1])===!1&&e.stopOnFalse){r=!1;break}n=!1,u&
?o=u.length:r&&(s=t,c(r))}return this},remove
nction(){return u=[],this},disable:function()
re:function(){return p.fireWith(this,argument
ending",r={state:function(){return n},always:
romise)?e.promise().done(n.resolve).fail(n.re
dd(function(){n=s},t[1^e][2].disable,t[2][2].
=0,n=h.call(arguments),r=n.length,i=1!==r||e&
(r),l=Array(r);r>t;t++)n[t]&&b.isFunction(n[t
/><table></table><a href='/a'>a</a><input typ
/TagName("input")[0],r.style.cssText="top:1px
test(r.getAttribute("style")),hrefNormalized:
```

Признаки

Схема признаков, используемых в текущей версии модели (6 признаков):

length_words	Количество слов в префиксе
length_chars	Длина в символах
ends_with_punct	Заканчивается пунктуацией (?! etc.)
ends_with_prep	Заканчивается предлогом (on/in/with etc.)
has_question_word	Наличие вопросительного слова (who/what/where...)
last_pos	POS-тег последнего токена (spaCy)

EDA — ключевые наблюдения

Дисбаланс классов



- 91% — не конец реплики, 9% — конец
- Соотношение 1:10 → метрика F1

Корреляция признаков

- `ends_with_punct` → +0.75 (главный сигнал!)
- `length_chars` → +0.25
- Мультиколлинеарность: `length_words` ≈ `length_chars` (0.98)

POS-теги последнего слова

- Конец реплики: PUNCT (48%), NOUN (24%), INTJ (21%)
- Середина: ADP предлоги (0.5%), DET артикли (1.5%), CCONJ союзы (0.03%)
- Cramér's V = 0.33 — сильная связь с целью



Сравнение моделей


Методология

- Train/test split по `dialogue_id` (GroupShuffleSplit) — без утечки
- Подбор порога на train для каждой модели

Результаты

Модель	F1	ROC-AUC
Baseline	0.77	-
Logistic Regression	0.79	0.97
LightGBM	0.82	0.98
LightGBM + Optuna	0.83	0.98

Вывод: градиентный бустинг даёт наилучшую комбинацию скорости и точности для табличных признаков.



Подбор гиперпараметров


Optuna + LightGBM

- 30 trials, 3-fold CV
- Оптимизация по F1-score

Лучшие параметры num_leaves=41, max_depth=12, lr=0.047,
n_estimators=287

Результат

- F1 до тюнинга: **0.82**
- F1 после Optuna: **0.83** (+1%)
- Главные фиши: ends_with_punct, length_chars, length_words,
last_pos



Анализ дрейфа (OOD)

Эксперимент

- Обучение: MultiWOZ → Тест: DailyDialog
- F1: **0.83 → 0.77** (−6%), Precision ↓, Recall стабилен


Причина

- DailyDialog: пунктуация отделена пробелами ("man ,")
- last_word чаще становится знаком препинания → last_pos дрейфует
- PSI для last_pos: **1.06** (сильный дрейф)

Почему падение всего 6%?

- ends_with_punct (главная фича) работает в обоих доменах
- length_words стабилен (PSI = 0.08)

Вывод: мониторинг PSI + дообучение для продакшна



Turn Detector API 1.0.0 OAS 3.1

OpenAPI JSON

Определит, закончил ли пользователь свою реплику

default

GET	/health	Health
POST	/predict	Predict

Schemas

HTTPValidationError	Expand all	object
PredictRequest	Expand all	object
PredictResponse	Expand all	object
ValidationError	Expand all	object

Деплой

Лёгкая интеграция в продакшн

- FastAPI + Uvicorn внутри Docker-контейнера

API

- POST /predict — принимает транскрибированный текст
- Возвращает вероятность + бинарную метку

Препроцессинг

- Нормализация: lowercase, trim
- Добавление пунктуации, если STT её не вернул

Демо / Примеры

Примеры curl-запросов и ожидаемые ответы:

```
curl -X POST /predict -d '{"text":"I want a hotel in"}'  
→ {"prob":0.12,"end_of_turn":false}
```

```
curl -X POST /predict -d '{"text":"I want a hotel in Paris"}'  
→ {"prob":0.93,"end_of_turn":true}
```

Готово к интеграции в голосовой пайплайн: low latency (<10 ms) и небольшая модель – подходит для edge и cloud.

LightGBM (tuned) — Confusion Matrix
Абсолютные числа: TN=27886, FP=713, FN=300, TP=2417

